

¿Cómo estimar el índice de Theil con la GEIH? Comparación de cuatro estimadores aplicado a la desigualdad del ingreso laboral en Colombia, 2018–2026

Gabriel Salcedo
Jerónimo Marín
Isaac Suarez
Santiago Velandia

Universidad del Rosario

Estadística

Octubre de 2026

Versión con control de cambios. Compara la primera entrega con la versión corregida.

Texto en azul: texto nuevo o corregido. ~~Texto rojo tachado~~: texto de la versión anterior.

Las tablas que cambiaron aparecen completas dos veces: la anterior en rojo y la corregida en azul. Las citas ahora salen de `references.bib`; por eso las referencias aparecen dos veces: la lista anterior tachada y la nueva, generada automáticamente.

Introducción

Justificación

Colombia es uno de los países más desiguales de América Latina: el Gini del ingreso de los hogares fue 0,551 en 2024, casi igual al 0,545 de 2000 ~~(DANE, 2025)~~(Departamento Administrativo Nacional de Estadística [DANE], 2025). Estas cifras se calculan a partir de encuestas, y por eso no son la desigualdad "real" sino una estimación de ella. ~~Por eso, detrás~~ Detrás de cada dato publicado hay decisiones ~~estadisticas~~ estadísticas sobre qué ~~estimadores se usan~~ estimador se usa y bajo qué supuestos.

El índice de Theil es una medida usual para este problema, pues ~~,~~ permite calcular la desigualdad ~~de ingreso yademas es capaz de descomponer el dato de~~ del ingreso y, además, descomponerla exactamente en desigualdad *entre* grupos y *dentro* de ellos ~~(Shorrocks, 1980)~~(Shorrocks, 1980). Pero hay varias formas de estimarlo con los mismos datos. Se puede calcular directamente sobre la muestra, con o sin los factores de expansión de la encuesta, o se puede suponer que el ingreso sigue una distribución lognormal, ~~lo que es usual en la distribuciones de ingreo~~un supuesto usual en las distribuciones de ingreso. Cada opción necesita supuestos distintos, y elegir mal puede producir sesgo.

En este proyecto queremos comparar, mediante un experimento de simulación, cuatro estimadores del índice de Theil en términos de sesgo, varianza, error cuadrático medio (ECM), eficiencia relativa y consistencia~~. Y~~ , y después usar el estimador que mejor se comporte para medir la desigualdad del ingreso laboral en Colombia entre 2018 y 2026.

Estado del arte

~~Theil (1967)~~ Theil (1967) propuso un índice que vale cero cuando todas las personas

ganan lo mismo y crece a medida que el ingreso se concentra. Este ~~indice posee~~ índice tiene varias propiedades que nos serán ~~utiles mas adelante, como:~~ útiles más adelante; la principal es que es aditivamente descomponible, y a partir de eso se puede medir ~~cuanto explica cada división (aditiva) el valor global del Theil~~ cuánto del Theil total explica cada partición de la población en grupos.

Por otro lado, para cuantificar la incertidumbre de cualquier estimador, ~~Efron y Tibshirani (1993)~~ Efron y Tibshirani (1993) desarrollaron el bootstrap, ~~él cual es un~~ un método que aproxima la distribución muestral de un estimador remuestreando los datos, y ~~Mills y Zandvakili (1997)~~ Mills y Zandvakili (1997) lo aplicaron a índices de desigualdad y a sus descomposiciones.

Para Colombia, ~~Sánchez-Torres (2017)~~ Sánchez-Torres (2017) encontró que cerca del 88 % de la desigualdad se da dentro de los departamentos, y ~~Ariza y Montes-Rojas (2017)~~ Ariza y Montes-Rojas (2017) mostraron que la informalidad aumenta la desigualdad del ingreso laboral en las ciudades. Sin embargo, estos trabajos calculan un único estimador sin justificar la elección, estudian un factor a la vez, usan datos anteriores a 2016 y no reportan la precisión de sus resultados. Este proyecto busca llenar ese vacío~~al validar primero~~ : primero valida el estimador y después ~~sí aplicarlo~~lo aplica.

Pregunta problema

De cuatro estimadores candidatos del índice de Theil —ponderado (A), sin ponderar (B), lognormal por momentos (C) y lognormal por máxima verosimilitud (D)—, ¿cuál tiene mejores propiedades estadísticas (menor sesgo, menor ECM y consistencia) para estimar la desigualdad del ingreso laboral a partir de la GEIH?

Objetivos

Objetivo general

Comparar las propiedades estadísticas de cuatro estimadores del índice de Theil mediante un experimento de simulación con la GEIH, y aplicar el estimador validado para medir y explicar la desigualdad del ingreso laboral en Colombia entre 2018 y 2026.

Objetivos específicos

1. Definir formalmente los cuatro estimadores candidatos (A, B, C y D), sus supuestos y las propiedades teóricas esperadas de cada uno (sesgo, consistencia, eficiencia y suficiencia).
2. Construir, a partir de la GEIH 2024 completa, un valor de referencia ("valor verdadero") del Theil contra el cual evaluar los cuatro estimadores.
3. Diseñar y ejecutar un experimento de simulación con submuestras de distintos tamaños para estimar el sesgo, la varianza, el ECM y la eficiencia relativa de cada estimador.
4. Determinar, con base en la evidencia del experimento, cuál de los cuatro estimadores es consistente y debe usarse en el análisis aplicado.
5. Construir ~~nueve~~ bases anuales comparables (~~enero–julio~~enero–junio de cada año, 2018–2026) y calcular con el estimador validado el Theil de cada año, excepto 2020, y su descomposición entre/dentro de grupos para las cinco dimensiones.
6. Estimar intervalos de confianza del 95 % por bootstrap y contrastar las hipótesis H1, H2 y H3.

Estimadores que pondremos a prueba

Sea y_i el ingreso laboral de la persona i y w_i su factor de expansión, para $i = 1, \ldots, n$. El parámetro de interés es el índice de Theil de la población de ocupados:

$$T = \frac{1}{N} \sum_{j=1}^{N} \frac{Y_j}{\mu_Y} \ln\left(\frac{Y_j}{\mu_Y}\right), \tag{1}$$

donde N es el tamaño de la población, Y_j el ingreso de cada persona y μ_Y su media.

~~Estimador~~ **Estimadores por sustitución (A y B).** Reemplazan la distribución poblacional por la muestral. El estimador **A** usa los factores de expansión, con $W = \sum_i w_i$ y $\hat{\mu}_w = \frac{1}{W} \sum_i w_i y_i$:

$$\hat{T}_A = \frac{1}{W} \sum_{i=1}^{n} w_i \frac{y_i}{\hat{\mu}_w} \ln\left(\frac{y_i}{\hat{\mu}_w}\right). \tag{2}$$

El estimador **B** ~~, solo~~ es el estimador A ~~pero~~ sin el factor de expansión, ~~por lo que es~~ es decir, la misma fórmula con $w_i = 1$ para todos. Como la GEIH no le da a todas las personas la misma probabilidad de ser encuestadas, B mide la desigualdad *de los encuestados* y no la de la población; por eso se espera que sea sesgado incluso con muestras muy grandes.

Estimadores lognormales (C y D). Si $\ln y \sim N(m, \sigma^2)$, entonces $T = \sigma^2/2$ ~~(Cowell, 2011)~~(Cowell, 2011), así que basta con estimar σ^2:

$$\hat{T}_C = \frac{1}{2}\ln\left(1 + \frac{s_y^2}{\bar{y}^2}\right), \qquad \hat{T}_D = \frac{1}{2}\cdot\frac{1}{n}\sum_{i=1}^{n}\left(\ln y_i - \overline{\ln y}\right)^2. \tag{3}$$

C despeja σ^2 igualando la media y la varianza muestrales del ingreso con las de una lognormal (método de los momentos). D usa el estimador de máxima verosimilitud de σ^2, que depende de los datos solo a través de $\sum \ln y_i$ y $\sum (\ln y_i)^2$.

Selección y exploración de bases de datos

Fuente

Se usa la **Gran Encuesta Integrada de Hogares (GEIH)** del ~~DANE (2026)~~DANE (2026): encuesta mensual, probabilística y de cobertura nacional, con una muestra de cerca de 315.000 hogares al año ~~(DANE, 2023)~~(DANE, 2023). Es la única fuente que reúne ingreso laboral y factores de expansión~~, esto es realmente útil~~. Esto es clave, porque sin factores de expansión no se podría construir el estimador A ni evaluar el sesgo de B. Para cada año se unen los meses de enero a ~~julio~~junio de tres módulos (ocupados, características generales y datos del hogar y la vivienda), lo que da ~~9 bases comparables~~nueve bases anuales (2018–2026). Cada una tiene **más de ~~50.000 observaciones~~ 140.000 ocupados y 12 variables** (Tabla 1), por lo que cumple los requisitos.

Tabla 1 — versión anterior

Variables seleccionadas de la GEIH

Variable	Código GEIH	Tipo / escala	Uso
Ingreso laboral mensual	INGLABO	Continua / razón	Cálculo del Theil
Factor de expansión	FEX_C18	Continua / razón	Ponderación (estimador A)
Nivel educativo	P3042 (antes P6210)	Cualitativa / ordinal	Dimensión 1
Cotización a pensión	P6920	Cualitativa / nominal	Formalidad (dimensión 2)
Posición ocupacional	P6430	Cualitativa / nominal	Formalidad (dimensión 2)
Estrato	P4030S1A1	Cualitativa / ordinal	Dimensión 3
Departamento	DPTO	Cualitativa / nominal	Región (dimensión 4)
Sexo	P3271 (antes P6020)	Cualitativa / nominal	Dimensión 5
Edad	P6040	Discreta / razón	Filtro ($\geq$ 15 años)
Zona	CLASE	Cualitativa / nominal	Descripción
Horas trabajadas	P6800	Discreta / razón	Descripción
Rama de actividad	RAMA2D_R4	Cualitativa / nominal	Descripción

Nota. Los códigos cambian entre los marcos muestrales 2005 y 2018 y se verificarán en el diccionario de cada año.

Tabla 1 — versión corregida

Variables seleccionadas de la GEIH

Variable	Código GEIH	Tipo / escala	Uso
Ingreso laboral mensual	INGLABO	Continua / razón	Cálculo del Theil
Factor de expansión	FEX_C_2011 (2018–2021); FEX_C18 (2022–2026)	Continua / razón	Ponderación (estimador A)
Nivel educativo	P3042 (antes P6210)	Cualitativa / ordinal	Dimensión 1
Cotización a pensión	P6920	Cualitativa / nominal	Formalidad (dimensión 2)
Estrato	P4030S1A1	Cualitativa / ordinal	Dimensión 3
Departamento	DPTO	Cualitativa / nominal	Región (dimensión 4)
Sexo	P3271 (antes P6020)	Cualitativa / nominal	Dimensión 5
Posición ocupacional	P6430	Cualitativa / nominal	Filtro (remunerados) y ajuste por no respuesta
Edad	P6040	Discreta / razón	Filtro ($\geq$ 15 años)
Zona	CLASE	Cualitativa / nominal	Descripción
Horas trabajadas	P6800	Discreta / razón	Descripción
Tamaño de la empresa	P3069 (antes P6870)	Cualitativa / ordinal	Descripción

Nota. Los códigos cambian entre el marco muestral antiguo (2018–2021) y el Marco 2018 (2022–2026); el código guarda, para cada año, el nombre original de cada variable.

Depuración

El principio de la depuración es *marcar, no borrar*: la base de cada año conserva a todos los ocupados, y cada criterio se guarda como un indicador. Así se puede verificar cuántas personas excluye cada paso (Tabla 2). Los criterios son:

- ~~Se conservan~~ **Edad:** ocupados de 15 años o más~~con ingreso laboral mayor que cero para evitar problemas con los logaritmos~~.
- **Remunerados:** se excluyen los trabajadores sin remuneración, porque su ingreso laboral es cero por definición.
- **Cobertura común:** los 24 departamentos que la encuesta cubre en todos los años. El Marco 2018 agrega nueve departamentos (San Andrés y los de Orinoquía-Amazonía) que no existen en 2018–2021, así que quedan fuera para que la serie sea comparable.
- **Ingreso positivo:** se excluyen los ingresos iguales a cero, porque el Theil y los estimadores lognormales usan logaritmos y $\ln 0$ no está definido.
- ~~Formal~~**Dimensiones completas:** la persona debe tener información en las cinco dimensiones.
- **No respuesta de ingreso:** quienes no reportan ingreso no se borran. Su peso se reparte entre quienes sí lo reportan dentro de celdas de posición ocupacional, formalidad, educación, región y sexo, de modo que el total del factor de expansión se conserva.

Las dimensiones se definen así. **Educación:** cinco niveles armonizados entre marcos (ninguno o preescolar, primaria, secundaria, media y superior). **Formalidad:** es formal quien cotiza a pensión ~~, según su posición ocupacional.~~ o ya está pensionado (P6920). **Estrato:** 1 a 6. **Región:** ~~regiones del DANE (~~cinco regiones dentro de la cobertura común (Bogotá, Caribe, Oriental, Central ~~,~~ y Pacífica~~, Bogotá, Amazonía-Orinoquía). Se usa el factor de expansión del Marco 2018 en todos los~~). **Sexo:** hombre o mujer.

El año 2020 se excluye del cálculo del Theil: por la recolección telefónica durante la pandemia, falta el ingreso de la mayoría de los ocupados y no se recogió el estrato (Tabla 2). Por eso el análisis aplicado usa ocho años~~para que la comparación 2018–2026 sea válida.~~ .

Tabla 2 — nueva

Trazabilidad de la depuración por año (enero–junio)

Año	Ocupados	Población de estudio	Entran al Theil	% del FEX total
2018	174.668	162.300	141.025	82,6
2019	168.441	156.616	151.283	87,6
2020	146.862	96.931	57.042	46,4
2021	146.094	136.479	129.750	86,2
2022	194.647	168.270	160.946	85,3
2023	183.136	160.299	157.776	88,3
2024	178.204	156.063	152.213	86,9
2025	176.176	154.659	153.340	89,1
2026	177.195	155.262	154.657	89,0

Nota. Población de estudio: cumple todos los criterios de la depuración. *Entran al Theil*: además reportan ingreso positivo. *% del FEX total*: porcentaje del factor de expansión de todos los ocupados que representan quienes entran al Theil, antes del ajuste por no respuesta. 2020 no se usa en el Theil.

Hipótesis

Todas las pruebas ~~las haremos~~ son unilaterales con $\alpha = 0{,}05$.

H1. El estimador ponderado (A) es consistente y tiene el menor ECM de los cuatro cuando el tamaño de muestra crece, mientras que B, C y D no convergen al valor verdadero.

Para cada competidor j y $n = 50.000$ se define, en cada réplica, la diferencia de pérdidas $d_j^{(r)} = (\hat{T}_A^{(r)} - T)^2 - (\hat{T}_j^{(r)} - T)^2$, y se contrasta:

$$H_0 : \bar{d}_j \geq 0 \qquad H_1 : \bar{d}_j < 0, \qquad j \in \{B, C, D\} \tag{4}$$

con una prueba t pareada sobre las R réplicas. Se concluye a favor de A si se rechaza H_0 para los tres competidores. La consistencia se evalúa además con la tendencia del ECM de cada estimador a lo largo de los cuatro tamaños de muestra.

H2 (aplicada~~- esto lo hacemos una vez ya hayamos elegido~~ , con el ~~mejor~~

estimador elegido). En 2026 la educación explica más desigualdad que cada una de las otras cuatro dimensiones.

$$H_0 : \ S_{edu} \leq S_k \text{ para algún } k \qquad\qquad H_1 : \ S_{edu} > S_k \text{ para todo } k \tag{5}$$

Se rechaza H_0 si el percentil 5 de cada diferencia bootstrap $S^{*b}_{edu} - S^{*b}_{k}$ es mayor que cero.

H3 (aplicada). La desigualdad del ingreso laboral fue menor en 2026 que en 2018.

$$H_0 : \ T_{2026} \geq T_{2018} \qquad\qquad H_1 : \ T_{2026} < T_{2018} \tag{6}$$

Se rechaza H_0 si el percentil 95 de las diferencias $T^{*b}_{2026} - T^{*b}_{2018}$ es menor que cero. Además de la decisión se reportará el tamaño de la diferencia, pues con muestras tan grandes casi todo resulta significativo.

Limitaciones. El valor verdadero del experimento es la propia GEIH 2024, no la población colombiana, así que la simulación evalúa los estimadores bajo un diseño que imita el real pero lo simplifica. Los factores de expansión de 2018–2021 provienen del marco muestral antiguo y los de 2022–2026 del Marco 2018, y el cuestionario también cambió; por eso parte de la diferencia entre 2018 y 2026 puede deberse al cambio metodológico y no a un cambio real de la desigualdad. El bootstrap remuestrea personas e ignora el muestreo por conglomerados, por lo que los intervalos pueden quedar algo estrechos. Las dimensiones están correlacionadas entre sí, los ingresos altos suelen subreportarse, y los resultados aplicados indican asociación, no causalidad.

Resumen de artículos relacionados

~~Mills y Zandvakili (1997)~~**Mills y Zandvakili (1997)**

Proponen el bootstrap para construir intervalos y pruebas sobre el Gini y el Theil y sus descomposiciones, con datos de panel de Estados Unidos. Muestran que diferencias aparentes entre grupos pueden no ser significativas incluso con muestras grandes. Tratan el

índice de desigualdad como lo que es, un estimador con distribución muestral.

~~Sánchez-Torres (2017)~~**Sánchez-Torres (2017)**

Con la ECH y la GEIH (2002–2015), el autor descompone el Theil entre y dentro de departamentos y el Gini por fuentes de ingreso. Encuentra que cerca del 88 % de la desigualdad ocurre dentro de los departamentos, que Chocó y La Guajira están entre los más desiguales y que el ingreso de los asalariados es la fuente que más aporta.

~~Ariza y Montes-Rojas (2017)~~**Ariza y Montes-Rojas (2017)**

Con un panel de 13 ciudades (2002–2015), modelos de efectos fijos y variables instrumentales, los autores muestran que la informalidad aumenta significativamente la desigualdad del ingreso laboral, y que la desigualdad ocurre casi toda dentro de las ciudades.

~~Bibliografía~~Referencias

~~Ariza, J., y Montes-Rojas, G. (2017). Labour income inequality and the informal sector in Colombian cities. , 77–98.~~

~~Cowell, F. A. (2011). *Measuring inequality* (3.ª ed.). Oxford University Press.~~

~~Cowell, F. A., y Jenkins, S. P. (1995). How much inequality can we explain? A methodology and an application to the United States. , 421–430.~~

~~Departamento Administrativo Nacional de Estadística DANE. (2023). *Metodología general Gran Encuesta Integrada de Hogares — GEIH* (DSO-GEIH-MET-001, versión 11).~~

~~Departamento Administrativo Nacional de Estadística DANE. (2025). *Pobreza monetaria en Colombia: Año 2024* Boletín técnico.~~

~~Departamento Administrativo Nacional de Estadística DANE. (2026). *Gran Encuesta Integrada de Hogares — GEIH, 2018–2026* Conjunto de datos.~~

~~Efron, B., y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.~~

~~Mills, J. A., y Zandvakili, S. (1997). Statistical inference via bootstrapping for measures of inequality. , 133–150.~~

~~Sánchez-Torres, R. M. (2017). Desigualdad del ingreso en Colombia: un estudio por departamentos. , 139–178.~~

~~Shorrocks, A. F. (1980). The class of additively decomposable inequality measures. , 613–625.~~

~~Theil, H. (1967). *Economics and information theory*. North-Holland.~~

Ariza, J., y Montes-Rojas, G. (2017). Labour income inequality and the informal sector in Colombian cities. *Cuadernos de Economía*, *36*(72), 77-98. https://doi.org/10.15446/cuad.econ.v36n72.65820

Cowell, F. A. (2011). *Measuring inequality* (3.ª ed.). Oxford University Press.

Departamento Administrativo Nacional de Estadística. (2023). *Metodología general Gran Encuesta Integrada de Hogares – GEIH* (DSO-GEIH-MET-001, versión 11). DANE. https://www.dane.gov.co/files/operaciones/GEIH/met-GEIH.pdf

Departamento Administrativo Nacional de Estadística. (2025). *Pobreza monetaria en Colombia: año 2024* (Boletín técnico). DANE. https://www.dane.gov.co/files/operaciones/PM/bol-PM-2024.pdf

Departamento Administrativo Nacional de Estadística. (2026). *Gran Encuesta Integrada de Hogares – GEIH, 2018–2026*. DANE. https://microdatos.dane.gov.co

Efron, B., y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall. https://doi.org/10.1201/9780429246593

Mills, J. A., y Zandvakili, S. (1997). Statistical inference via bootstrapping for measures of inequality. *Journal of Applied Econometrics*, *12*(2), 133-150.

Sánchez-Torres, R. M. (2017). Desigualdad del ingreso en Colombia: un estudio por departamentos. *Cuadernos de Economía*, *36*(72), 139-178. https://doi.org/10.15446/cuad.econ.v36n72.65880

Shorrocks, A. F. (1980). The class of additively decomposable inequality measures. *Econometrica*, *48*(3), 613-625. https://doi.org/10.2307/1913126

Theil, H. (1967). *Economics and information theory*. North-Holland.